



Estudios de Asociación Genómica Libres de Sesgos para Rasgos Complejos y Enfermedades en Más de 100 mil Mexicanos

Examen de candidatura

Ing. Roberto Olvera Hernández

Programa de Doctorado en Ciencias Biomédicas (PDCB)

Centro de Ciencias Genómicas (CCG)

Universidad Nacional Autónoma de México (UNAM)

4 de agosto de 2026



Centro de Ciencias Genómicas

En México, 4 de cada 10 muertes registradas se relacionan con enfermedades complejas




Figura 1: El 41.4 % de las muertes en México son por enfermedades cardio-metabólicas. La mortalidad por enfermedad cardíaca y diabetes mellitus sigue en aumento (1998–2022). Fuente: Estadísticas vitales (INEGI) y proyecciones de población (CONAPO), vía Agudelo-Botero y Dávila-Cervantes (2026).

La diabetes es más común y más mortal en México que en países de altos ingresos




Figura 2: En la cohorte MCPs ($N \approx 150,000$), la diabetes explica 1 de cada 3 muertes entre 35–74 años ($RR = 5.4$ a los 35–59). Recuperado de Alegre-Díaz Jesus *et al.* (2016).

Las poblaciones latinoamericanas están subrepresentadas en estudios genómicos





Figura 3: Ancestría de participantes en GWAS por el tiempo, comparado con población global. Recuperado de Martin *et al.* (2019).


Total GWAS participants diversity

Version 1.0.0. Last check for data: 2025-09-05 00:34:26 .




gwasdiversitymonitor.com

La distancia genética respecto a poblaciones europeas está correlacionado con la capacidad de predicción



(a) Estructura poblacional del estudio.



(b) Decaimiento continuo de precisión.

Figura 4: ATLAS Ding *et al.* (2023).

La reducción de predicción lo podemos ver directamente en México




Figura 5: Decaimiento de precisión de PGS en MCPS. Los PGS derivan de UKB y decaen con el porcentaje de ancestría indígena mexicana (Ziyatdinov *et al.* 2023, *Nature*).

La diversidad genética es un espectro continuo, no categorías discretas




Figura 6: La diversidad genética opera en múltiples escalas temporales: arcaica, continental y sub-continental (Palma-Martínez, Posadas-García, Shaukat *et al.* [2025](#), *Nature Medicine*).

El genoma mexicano es mestizo y tiene origen en su pasado colonial europeo




Figura 7: Mosaico de bloques de haplotipos en cromosomas admixtos (Ziyatdinov *et al.* 2023, *Nature*).




Figura 8: Estructura subcontinental de México (Moreno-Estrada *et al.* 2014, *Science*).




Figura 9: Agrupamiento ADMIXTURE (Sohail *et al.* 2023, *Nature*).


Cuatro rutas para modelar la genética en poblaciones diversas

Identidad por Descendencia (IBD)

Ej. Palma-Martínez, Posadas-García,

López-Ángeles et al. (2024), Cai y Browning

(2025), Marsico et al. (2026) y Micheletti et al. (2025)



Pipeline GG-NC. Detección de comunidades (Palma-Martínez, Posadas-García, López-Ángeles et al. 2024).


Cuatro rutas para modelar la genética en poblaciones diversas

Identidad por Descendencia (IBD)

Ej. Palma-Martínez, Posadas-García,

López-Ángeles et al. (2024), Cai y Browning


(2025), Marsico et al. (2026) y Micheletti et al. (2025)



Pipeline GG-NC. Detección de comunidades (Palma-Martínez, Posadas-García, López-Ángeles et al. 2024).

PRS multi-ancestría

Ej. PRS-CSx, CT-SLEB, BridgePRS, GAUDI



Ejemplo de PRS multi-ancestría (Ruan et al. 2022, Nature Genetics).

Cuatro rutas para modelar la genética en poblaciones diversas


Identidad por Descendencia (IBD)

Ej. Palma-Martínez, Posadas-García,

López-Ángeles et al. (2024), Cai y Browning

(2025), Marsico et al. (2026) y Micheletti et al.


(2025)



Pipeline GG-NC. Detección de comunidades (Palma-Martínez, Posadas-García, López-Ángeles et al. (2024)).

PRS multi-ancestría


Ej. PRS-CSx, CT-SLEB, BridgePRS, GAUDI



Ejemplo de PRS multi-ancestría (Ruan et al. 2022, Nature Genetics).

Ancestría local (LAI)

Ej. Tractor, Tractor-Mix, Recomb-Mix, Orchestra



Ejemplo de ancestría local (Tan et al. 2026, Nature Genetics).

Cuatro rutas para modelar la genética en poblaciones diversas


Identidad por Descendencia (IBD)

Ej. Palma-Martínez, Posadas-García,

López-Ángeles et al. (2024), Cai y Browning

(2025), Marsico et al. (2026) y Micheletti et al.


(2025)



Pipeline GG-NC. Detección de comunidades (Palma-Martínez, Posadas-García, López-Ángeles et al. (2024).

PRS multi-ancestría


Ej. PRS-CSx, CT-SLEB, BridgePRS, GAUDI



Ejemplo de PRS multi-ancestría (Ruan et al. 2022, Nature Genetics).

Ancestría local (LAI)


Ej. Tractor, Tractor-Mix, Recomb-Mix, Orchestra



Ejemplo de ancestría local (Tan et al. 2026, Nature Genetics).

GWAS familiares

Ej. Estimador Robusto, snipar



Ejemplo de GWAS familiares (Young, Benonisdottir et al. 2019, Science).

Cuatro rutas para modelar la genética en poblaciones diversas


Identidad por Descendencia (IBD)

Ej. Palma-Martínez, Posadas-García,

López-Ángeles et al. (2024), Cai y Browning

(2025), Marsico et al. (2026) y Micheletti et al.


(2025)



Pipeline GG-NC. Detección de comunidades (Palma-Martínez, Posadas-García, López-Ángeles et al. (2024).

PRS multi-ancestría


Ej. PRS-CSx, CT-SLEB, BridgePRS, GAUDI



Ejemplo de PRS multi-ancestría (Ruan et al. 2022, Nature Genetics).

Ancestría local (LAI)


Ej. Tractor, Tractor-Mix, Recomb-Mix, Orchestra



Ejemplo de ancestría local (Tan et al. 2026, Nature Genetics).


GWAS familiares

Ej. Estimador Robusto, snipar



Ejemplo de GWAS familiares (Young, Benonisidottir et al. 2019, Science).

Sesgos en GWAS



Family-based GWAS




Figura 10: Señales capturadas por un GWAS de individuos relacionados y familias. Recuperado de Young, Benonisdottir *et al.* (2019).

Los FGWAS aíslan los Efectos Genéticos Directos (DGEs)

(Visscher *et al.* 2006, *PLOS Genetics*; Young, Benonisdottir *et al.* 2019, *Science*)

$$y_{ij} = \delta g_{ij} + \alpha g_{\text{par}(i)} + \epsilon_{ij}$$

- ▶ δ = DGE
- ▶ α = coeficiente no-transmitido
- ▶ $g_{\text{par}(i)}$ = genotipo parental

GWAS estándar: $\hat{\beta} = \delta + \alpha$

Family-based GWAS




Figura 10: Señales capturadas por un GWAS de individuos relacionados y familias. Recuperado de Young, Benonisdottir *et al.* (2019).

Los FGWAS aíslan los Efectos Genéticos Directos (DGEs)

(Visscher *et al.* 2006, *PLOS Genetics*; Young, Benonisdottir *et al.* 2019, *Science*)

$$y_{ij} = \delta g_{ij} + \alpha g_{\text{par}(i)} + \epsilon_{ij}$$

- ▶ δ = DGE
- ▶ α = coeficiente no-transmitido
- ▶ $g_{\text{par}(i)}$ = genotipo parental

GWAS estándar: $\hat{\beta} = \delta + \alpha$

PERO

Evidencia de una señal biológica **verdadera**

vs.

Limitado a solamente individuos con **ambos** padres genotipados

Family-based GWAS




Figura 10: Señales capturadas por un GWAS de individuos relacionados y familias. Recuperado de Young, Benonisdottir *et al.* (2019).

Los FGWAS aíslan los Efectos Genéticos Directos (DGEs)

(Visscher *et al.* 2006, *PLOS Genetics*; Young, Benonisdottir *et al.* 2019, *Science*)

$$y_{ij} = \delta g_{ij} + \alpha g_{\text{par}(i)} + \epsilon_{ij}$$

- ▶ δ = DGE
- ▶ α = coeficiente no-transmitido
- ▶ $g_{\text{par}(i)}$ = genotipo parental

GWAS estándar: $\hat{\beta} = \delta + \alpha$

PERO

Evidencia de una señal biológica **verdadera**

vs.

Limitado a solamente individuos con **ambos** padres genotipados

Recuperar poder estadístico es **prioridad**

El estimador robusto (Guan et al. 2025)





Figura 11: Muestra particionada por alelos no transmitidos observados (Guan et al. 2025, *Nature Genetics*).

Population-based GWAS

(All genotyped individuals)



Family-based GWAS designs

- Traditional designs; see Benyamin et al. (2006)
- Sibling-pairs (Howe et al. 2022)
- Parent-offspring trios & Sibling-pairs (Young et al. 2022)
- Robust Estimator (Guan et al. 2025)

Figura 12: Ganancia de tamaño de muestra efectivo (N_{eff}) respecto al diseño de hermanos (Guan et al. 2025, *Nature Genetics*).

Limitaciones: Validez interna vs. Portabilidad

- ✓ **FGWAS resuelve validez interna:** asociaciones limpias de confusión ambiental y estratificación.
- ✗ **No garantiza portabilidad:** $>85\%$ del decaimiento de PRS entre poblaciones se debe a diferencias en LD y MAF (Zhang y Conley 2024).

Conclusión: Para predecir en mexicanos, necesitamos hacer FGWAS **directamente en mexicanos**.

En resumen...

México tiene **140,000 genomas familiares** en el estudio MCPS.

Tenemos el **estimador robusto** para GWAS familiares.

Podemos construir el **primer atlas genómico libre de confusión** para rasgos complejos en mexicanos.

Objetivos de investigación

Objetivo principal

Estimar **efectos genéticos directos (DGEs)** para una amplia gama de rasgos complejos y enfermedades en una cohorte *mexicana*, utilizando el MCPS y nuevos estimadores FGWAS para aumentar drásticamente el poder estadístico.

Objetivos de investigación


Objetivo principal

Estimar **efectos genéticos directos (DGEs)** para una amplia gama de rasgos complejos y enfermedades en una cohorte *mexicana*, utilizando el MCPS y nuevos estimadores FGWAS para aumentar drásticamente el poder estadístico.


Hipótesis principal

Para la población mestiza del MCPS, un FGWAS con estimador robusto a mestizaje reciente cuantificará DGEs en múltiples rasgos complejos, superando otros diseños para identificar falsos-positivos de PopGWAS y revelar nuevos *loci* ocultos.


Objetivos específicos



Metodología: Resumen visual



Diseño experimental: Escalamiento incremental



Datos de entrada: Fenotipos


Estandarización de **fenotipos** y **covariantes** (age, age2, sex, PC1-7) respecto al *GWAS Atlas* de MCPS para mejor comparabilidad

Behavioural

1. Educational attainment
2. Age of first pregnancy
3. Income level
4. Smoking vs. never
5. Current smoking vs. not
6. Current smoking vs. former
7. Frequency of smoking
8. Frequency of alcohol

Biomedical

1. Asthma
2. Systolic Blood Pressure (SBP)
3. Diastolic Blood Pressure (DBP)
4. Height
5. Body-Mass Index (BMI)
6. *Clinical* LDL Cholesterol (LDL)
7. HDL Cholesterol (HDL)
8. Self-reported hypertension
9. Self-reported diabetes



**PhD. Diego Aguilar
Ramírez**

Intermediate Research Fellow
CTSU, NDPH – University of
Oxford



PhD. Erini Trichia
Senior Statistical

Epidemiologist
CTSU, NDPH – University of
Oxford

Datos de entrada: Genotipos


TOPMed-imputed y **GSAv2-CHIP** faseados previamente por MCPS con *SHAPEIT-4/5*

Young, Nehzati *et al.* (2022) recomiendan **INFO** ≥ 0.99

TOPMed-imputed y **GSAv2-CHIP** convertidos a BGEN con *plink2* para mejor compatibilidad

- ▶ Solo SNPs
- ▶ Eliminar variantes duplicadas
- ▶ $\text{GENO} \geq 5\%$
- ▶ $\text{MAF} \geq 1\%$

GSAv2-CHIP 341,441 variantes (140,829 individuos)
TOPMed-Imputed 1,076,402 variantes (140,829 individuos)




PhD. Alejandra Vergara-Lope
 Genetic Epidemiologist
 CTSU, NDPH – University of Oxford




PhD. Jason Torres
 Senior Genetics Epidemiologist
 CTSU, NDPH – University of Oxford


Flujo de trabajo de SNIPAR



Selección de subcohortes



Tamaños Efectivos de Muestra



El estimador robusto tiene un mayor poder estadístico que el modelo de Young, Nehzati *et al.* (2022)

Figura 13: Comparación de tamaños efectivos de muestra para todos los rasgos en dos estimadores de FGWAS. El estimador robusto vs. de pares de hermanos y trios parentales, incremento de 36.58 % ($SD \pm 6.78$ %). Barras de error representan intervalos de confianza del 95 %.

Comparación entre estimaciones de heredabilidad




Figura 14: Comparación de estimaciones de heredabilidad derivadas de FGWAS contra PopGWAS. Cada punto representa un rasgo complejo. Los colores representan la clasificación. La línea punteada representa la línea de identidad. Barras de error representan intervalos de confianza al 95 %.

Comparación de prevalencias entre subcohortes




Figura 15: Comparación de prevalencias. Prevalencias de fenotipos por subcohorta. (Young, Nehzati et al. [2022](#), *Nature Genetics*)

Comparación entre estimaciones de heredabilidad

Trait	h ² (Pop)	h ² (DGE)	SMD
Higher frequency of alcohol consumption	-0.024	0.021	1.47
HDL cholesterol	0.089	0.145	1.19
Diabetes	0.219	0.302	0.99
DBP	0.091	0.094	0.09
Current smoking vs not	0.025	0.026	0.00
Higher frequency of smoking	0.007	0.005	-0.08
Current smoking vs former	0.021	-0.001	-0.25
SBP	0.120	0.110	-0.28
BMI	0.194	0.183	-0.30
Apolipoprotein B (ApoB) (g/l)	0.149	0.131	-0.40
HbA1c	0.184	0.161	-0.53
Ever smoking vs never	0.037	0.019	-0.57
LDL cholesterol	0.146	0.111	-0.81
Hypertension	0.149	0.101	-0.98
Educational Attainment	0.072	0.011	-2.05
Height	0.331	0.225	-2.26




Figura 16: Diferencias normalizadas entre estimaciones de heredabilidad. Las líneas verticales en la gráfica indican CI 95 %.

Las subcohortes tiene diferencias sistemáticas por sesgos de averiguación




Figura 17: Diferencias por sesgos de averiguación. Diferencias de medias estandarizadas (SMD) entre subcohortes.

Atenuación a nivel de *locus* independientes (Clumping)

Fenotipo	SNP	Gen	PopGWAS β	FGWAS β	$\Delta\beta$	FDR	Patrón de Atenuación
Diabetes	chr6:20660459:G:A	CDKAL1	-0.178	-0.010	-0.168	$1,4 \times 10^{-8}$	Alto: Gran efecto poblacional; efecto directo cercano a cero.
Diabetes	chr9:22137686:T:G	CDKN2B	-0.163	-0.009	-0.154	$5,2 \times 10^{-8}$	Alto: Asociación inflada por sesgos/confusión.
LDL	chr5:156924336:T:C	TIMD4	-0.049	-0.016	-0.032	0.145	Fuerte: Efecto directo $\sim 3\times$ menor.
Estatura	chr7:44189469:C:T	GCK	-0.094	-0.077	-0.017	0.899	Moderado: Efecto conservado, ligera sobreestimación.
HbA1c	chr19:44908822:C:T	APOE	0.498	0.481	0.017	0.966	Estable: Efecto directo robusto, mínima confusión.

Cuadro 1: Resumen de atenuación en *loci* representativos (PopGWAS vs FGWAS).

Frecuencias alélicas por ancestría continental (MCPS)

Gen	locus	Freq. IMX	Freq. EUR	Δ (IMX - EUR)
<i>CDKAL1</i>	chr6:20660459:G:A	25.6 %	34.2 %	-8,6 %
<i>CDKN2B</i>	chr9:22137686:T:G	34.1 %	29.8 %	+4,3 %
<i>GCK</i>	chr7:44189469:C:T	19.3 %	20.5 %	-1,2 %
<i>TIMD4</i>	chr5:156924336:T:C	53.0 %	30.0 %	+23,0 %

Cuadro 2: Frecuencias alélicas en subpoblaciones de MCPS. IMX = Indígena Americano, EUR = Europeo. Datos extraídos del MCPS Allele Frequency Browser (<https://rgc-mcps.regeneron.com/home>).

Conclusiones: Explicando la Deflación Poblacional

1. Patrón de Heredabilidad

Encontramos una fuerte atenuación en rasgos sociales, pero una inversión paradójica ($h_{\text{direct}}^2 > h_{\text{pop}}^2$) para la diabetes en nuestra cohorte mestiza.

2. Sesgos de Averiguación

Comprobamos que las subcohortes tienen diferencias sistemáticas: las familias concentran individuos mayores, con más ascendencia indígena y mayor carga cardiometabólica.

3. El Origen de la Inflación

Al excluir familias, el PopGWAS sufre restricción de varianza y su ajuste imperfecto (PCs) absorbe el entorno compartido. Esto infla los *loci* independientes, pero deflata la varianza genética global.

Current collaborations



PhD. Jason Torres
Senior Genetics Epidemiologist
CTSU, NDPH – University of Oxford



PhD. Mashaal Sohail
Main PhD Supervisor
CCG – UNAM



PhD. Alexander S. Young
Mendelian Imputation author
Human Genetics Dept. – UCLA



PhD. Carla D. Robles Espinoza
Member of Tutor Committee
LIIGH – UNAM



PhD. Jaime Berumen Campos
Member of Tutor Committee
MCPS P.I. | UIME – UNAM



¡GRACIAS A TODXS!



Sohail Lab

Centro de Ciencias Genómicas (CCG)
Universidad Nacional Autónoma de México (UNAM)
Cuernavaca, Morelos, MX.



Mexico City Prospective Study (MCPS) team

Clinical Trial Service Unit (CTSU)
University of Oxford
Oxford, Oxfordshire, U.K.